



ZASTOSOWANIE METOD XAI DO INTERPRETACJI KLASYFIKACJI DŹWIĘKÓW OTOCZENIA

Porównanie SVM, ConvNeXt-Tiny i AST oraz
interpretacja decyzji za pomocą SHAP, CAM,
Integrated Gradients i Attention Rollout


CEL PROJEKTU

- Klasyfikacja dźwięków otoczenia - zadanie rozpoznawania klasy dźwięku na podstawie nagrania audio.
- Wiele modeli uczenia maszynowego działa jak czarna skrzynka.
Pytanie: Czy model uczy się właściwych wzorców
- XAI umożliwia:
 - budowanie zaufania do modelu
 - wykrywanie przypadkowych korelacji zamiast prawdziwej przyczyny
 - debugowanie

ZBIÓR DANYCH ESC-50

- 2000 nagrań WAV, 50 klas dźwięków
- Każde nagranie trwa dokładnie 5 sekund
- 5 gotowych foldów (po 8 nagrań/klasę/fold)

Grupa	Przykłady
Zwierzęta	dog, rooster, pig, cow, frog
Przyroda	rain, sea_waves, thunderstorm
Człowiek	crying_baby, sneezing, footsteps
Wnętrze domu	door_knock, vacuum_cleaner, clock_tick
Transport	helicopter, siren, engine, train



ANALIZA ZBIORU

EKSTRAKCJA CECH

- 12 typów cech
- łącznie 182 wartości na nagranie
- Agregacja – średnia i odchylenie standardowe


CECHA	WYMIAR	WARTOŚCI
MFCC / Δ / Δ^2	20 x 3	120
Chroma STFT	12	24
Spectral Contrast	7	14
Tonnetz	6	12
Centroid/Rolloff/Flatness/Bandwidth	4	8
ZCR + RMS Energy	2	4


ŚCIEŻKA	WEJŚCIE	MODEL	XAI
Klasyczne	182 cechy numeryczne	SVM (RBF, C=10)	SHAP
Głębokie (CNN)	Mel-spektrogram	ConvNeXt-Tiny (transfer learning)	GradCAM++, LayerCAM, ScoreCAM, XGradCAM, Integrated Gradients
Transformer	Mel-spektrogram	AST (bioamla/ast-esc50)	Integrated Gradients, Attention Rollout

TRZY PODEJŚCIA

SVM

- **StandardScaler + SVC(kernel="rbf", C=10, gamma="scale")**
- **5-fold CV**
- **Średnia dokładność: 60.30% (SVM).
(Dla porównania LightGBM: 58.35%)**
- **Najlepszy fold: 65.25% acc):**





XAI JAKO SELEKCJA CECCH


- Trzy metody selekcji cech




SHAP – SHAPLEY ADDITIVE EXPLANATIONS

- Oparty na wartościach Shapleya z teorii gier
- Każda cecha dostaje „sprawiedliwy” wkład w odchylenie predykcji od wartości oczekiwanej
- Cechy o równym wkładzie dostają równe wartości
- `shap.Explainer(model.predict_proba, X_background)`
PermutationExplainer, ponieważ SVM to czarna skrzynka,
tło = 100 losowych próbek

WYJAŚNIENIE GLOBALNE

- **Najważniejsza cecha:**
delta_mfcc2_1_std
- **Pochodne MFCC ważniejsze niż MFCC**
- **14 z 20 top cech to MFCC lub ich pochodne**






WYJAŚNIENIE DLA KLASY

(BEESWARM)

WYJAŚNIENIE LOKALNE (WATERFALL)




MODEL CNN: CONVNEXT-TINY

- Sieć konwolucyjna pretrenowana na ImageNet
- Wejście: mel-spektrogram jako obraz
- Modyfikacje:
 - Wejście 1-kanałowe
 - Nowa głowa klasyfikacyjna
 - SpecAugment
- Trening
 - Faza 1 (20 epok): zamrożony backbone, trenowana tylko głowa, LR=1e-3
 - Faza 2 (50 epok): fine-tuning całej sieci, LR=1e-4

WYNIKI

- Średnia: 74,45% (+14 pp względem SVM)
- Najlepszy model (Fold 4) użyty do przetestowania metod XAI


Fold	Dokładność
1	72.75%
2	75.25%
3	76.25%
4	77.25%
5	70.75%



CLASS ACTIVATION MAPS (CAM)

INTEGRATED GRADIENTS

- Atrybucja = całka gradientu po ścieżce od baseline do wejścia
- Baseline: macierz zer – brak dźwięku
- 50 kroków aproksymacji całki



TRANSFORMER AST

- Audio Spectrogram Transformer – ViT zaadaptowany do spektrogramów audio
- Model bioamla/ast-esc50, dostrojony na zbiorze ESC-50

ATTENTION ROLLOUT

- Analiza przepływu informacji
- Uwaga $\neq$ ważność cech
- Nie uwzględnia wartość
- Brak korelacji z innymi miarami

